

Projet d'études M1 Big Data & IA



RÉPUBLIQUE
FRANÇAISE

Liberté
Égalité
Fraternité

défis.data.gouv.fr

Les Françaises et Français face à l'information

- Saison 3

Ce projet est proposé dans le cadre de l'Open Data University.

Contexte du projet

Description rapide des utilisateurs, de la problématique, de l'état de l'art et des besoins.

En 2023, l'ARCOM établissait dans son [rapport sur la représentation des femmes à la télévision et à la radio](#), qu'elles ne représentaient que **34% du temps de parole** des émissions. En 2013, [le journal Le Monde publiait un article](#) qui titrait “en dix ans, le nombre de faits divers dans les JT a augmenté de 73 %”.

Télévision et la radio sont touchées par l'évolution des modes de consommation de l'information. Par exemple, [une autre étude de l'ARCOM](#) montre que **58% des Françaises et Français qui s'informent au moins une fois par jour le font sur les réseaux sociaux ou plateformes de vidéo** (11% exclusivement). Néanmoins, elles continuent de rassembler une audience large et leur influence sur l'exposition médiatique fait l'objet de nombreuses études et analyses. Ainsi, **la représentation des femmes à l'écran et aux micros** fait l'objet d'une attention particulière récente des pouvoirs publics. À titre d'exemple, [l'étude annuelle de l'ARCOM](#) sur le sujet n'est menée qu'à partir de 2016 (même si elle collecte des données sur la représentation des femmes depuis plus longtemps).

Les méthodes de collecte ont également évolué. Si les méthodes statistiques manuelles (échantillonnage et annotation manuelle) sont toujours d'actualité, des méthodes basées sur l'intelligence artificielle permettent **de produire plus rapidement et à moindre coût des données d'analyse de la représentation genrée dans l'audiovisuel** (détection automatique genrée du temps de parole, détection automatique de thèmes abordés à partir de retranscription, ...). C'est le sens du [projet de recherche Gender Equality Monitor](#) porté (entre autres) par l'Institut national de l'audiovisuel (INA).

La problématique

Ce projet vous propose d'enquêter à la fois sur **l'offre d'information** et ses potentiels biais de représentation, mais aussi sur la **demande et l'évolution des modes de "consommation"** de celle-ci :

1. **L'évolution des thèmes diffusés à la télévision et à la radio** française ;
2. **La représentation des femmes au sein des émissions** diffusées ;
3. Et l'évolution du **rapport des français à l'information et à l'audiovisuel**.

Objectifs du projet

L'objectif général du projet et les impacts recherchés.

Les travaux réalisés dans le cadre de ce projet permettront :

- à chaque citoyen **de prendre conscience des représentations véhiculées - explicitement ou implicitement - à la télévision et à la radio**
- aux associations de défense de juste représentation des femmes dans le paysage audiovisuel **d'appuyer leur plaidoyer**, et de le faire évoluer suivant les tendances qui se dessinent
- aux pouvoirs publics, comme aux chaînes de télévision, **de prendre des mesures éclairées** pour favoriser une représentation plus fidèle à celle de la population française.

Réalisations possibles

Les types de production qui peuvent être attendus des élèves.

Ce projet s'inscrit dans le cadre de l'Open Data University, vous êtes libres de choisir les livrables que vous jugerez les plus pertinents pour répondre au mieux à la problématique proposée. Voilà quelques exemples de réalisations possibles pour vous aider dans votre démarche :

- **Tableau de bord** qui permet de rendre compte de l'évolution des thèmes abordés lors des journaux télévisés. Ces analyses peuvent permettre de comprendre l'évolution d'un thème, d'en déduire les causes conjoncturelles (un événement en particulier), mais aussi les tendances plus structurelles. Par exemple, vous pouvez comparer l'évolution des sujets 'Faits divers' entre les JT de France 2 et TF1.

- **Data science** - Une évaluation de la proximité des journaux télévisés des différentes chaînes à partir des thèmes diffusés. Pour cela, il est possible d'utiliser des algorithmes d'apprentissage machine (KNN, Random Forest).
- **Datavisualisations** qui montrent la répartition du temps de parole des femmes par année et par chaînes.
- **Edito / Traitement des données** - Un article qui met en lumière les résultats de sondages et d'études sur le rapport des français à l'information. Il s'agira notamment de prendre en considération les bonnes pratiques de **traitement et d'interprétation de ces données** (échantillonnage, marges d'erreur, ...). Vous pouvez reproduire des datavisualisations d'après des données brutes des études.

(Bonus) Edito / Traitement des données - Un article qui décrypte la répartition du temps de parole entre les hommes et les femmes par sujet. Par exemple, on pourrait se demander si la part de la parole des femmes est inférieure (ou non) dans les sujets "*sport*" à celle dans les sujets "*immobilier*". Pour cela, vous pouvez **utiliser des outils existants de reconnaissance genrée de voix** et discours sur des données audio (ou issues de vidéos), comme l'outil [inaSpeechSegmenter](#) de l'INA (construit sur un réseau neuronal convolutif (ou CNN)). Vous pourriez ensuite mettre en parallèle ces segments avec d'autres analyses textuelles des retranscriptions (e.g. *topic classification*).

Remarque : Ce bonus nécessite au préalable d'accéder à des données audio et/ou vidéo pour lesquelles **vous avez les droits**. L'INA peut vous [mettre à disposition certains jeux de données](#), mais vous devrez en respecter les CGU. Il existe des jeux de données en open data, mais [leur pertinence est à évaluer](#).

Les travaux déjà réalisés par d'autres étudiantes et étudiants

Vous pouvez retrouver les réalisations d'autres étudiantes et étudiants en fin de page. N'hésitez pas à vous en inspirer !

Ce défi est-il pour moi ?

Tous les défis sont accessibles à différents niveaux (les différentes **réalisations possibles** mobilisent des compétences hétérogènes pour un même défi).

Néanmoins, ce défi semble particulièrement adapté (mais pas exclusivement) à des participants de niveau : **Intermédiaire**

La principale difficulté identifiée est : *la réalisation bonus sur la répartition de temps de parole selon les sujets nécessite d'avoir accès à des données intéressantes.*

Pour faire votre choix, vous pouvez aussi vous appuyer sur :

- les réalisations possibles (voir ci-dessus)
- ces mots-clés : tableau de bord, data science, traitement automatique du langage (TAL)

Valorisation du projet

La mise en avant des réalisations

Pour valoriser vos travaux, nous vous invitons à les partager avec l'ensemble de la communauté en publiant une réutilisation sur data.gouv.fr. Cela vous permettra notamment de :

- Profiter d'une visibilité accrue
- Obtenir des retours constructifs
- Engager un dialogue avec les producteurs de données
- Inspirer les autres

La marche à suivre est détaillée dans [ce guide](#). Nous avons hâte de voir vos réalisations !

Aspects techniques

Les contraintes techniques du projet : environnement matériel et logiciel, outils de développement, méthodologies, ressources de calcul, etc.

De nombreuses données ouvertes sont mises à votre disposition pour vous aider à répondre au projet proposé. La liste ci-dessous constitue une première base à exploiter dans le cadre du projet, elle est non exhaustive et nous vous encourageons à explorer davantage de données ouvertes.

Il peut être intéressant de jeter un œil aux publications de [l'équipe du projet GEM](#) de l'INA, vous en [trouverez une partie ici](#) et une [liste plus longue là](#).

Des visualisations sont disponibles sur le site data.ina.fr qui peut être également une bonne source d'inspiration.